



# Aplicação de Redes Neurais Artificiais

## Para previsão de séries temporais

STA13828 - Séries Temporais I  
Apresentação & Relatório por Igor Boaventura  
[Leia o relatório na íntegra](#)



# Sumário

## Breve resumo:

Neste relatório tratamos sobre o emprego de Redes Neurais Artificiais (RNAs) na previsão de séries temporais. Apresentando uma explicação sucinta sobre o funcionamento dessas redes, tanto de forma gráfica quanto matemática, o relatório se aprofunda na aplicação prática. Ao comparar os resultados de um modelo proposto no artigo original com uma replicação realizada, são exploradas as diferenças entre os resultados apresentados. A conclusão destaca não apenas a eficácia das RNAs na previsão, mas também ressalta a persistente complexidade na determinação da arquitetura ideal dessas redes neurais.

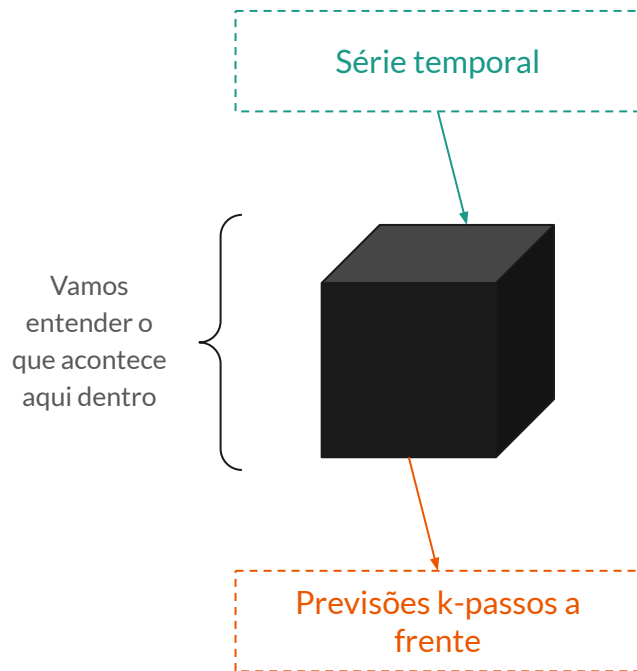
1. Introdução ao tema
2. Como funciona a RNA?
3. Aplicação
  - a. Apresentação dos dados
  - b. Metodologia
  - c. Resultados
4. Conclusão

# 1. Introdução ao tema

À medida que a complexidade das análises de dados aumenta, métodos como Redes Neurais Artificiais (RNAs), tornam-se ferramentas para **compreender padrões** em conjuntos de dados.

Neste caso, vamos explorar a aplicação de **RNAs na previsão de séries temporais**.

Antes precisamos compreender que as RNAs não são “caixas pretas”. Desmistificar esse conceito é fundamental para que problemas futuros sejam resolvidos com maior facilidade, sabendo o que está acontecendo ao rodar uma função no R.






## 2. Como funciona a RNA?

### Camada de entrada

Para explicar em um contexto mais simples, vamos para um exemplo externo ao principal (previsão de séries temporais).



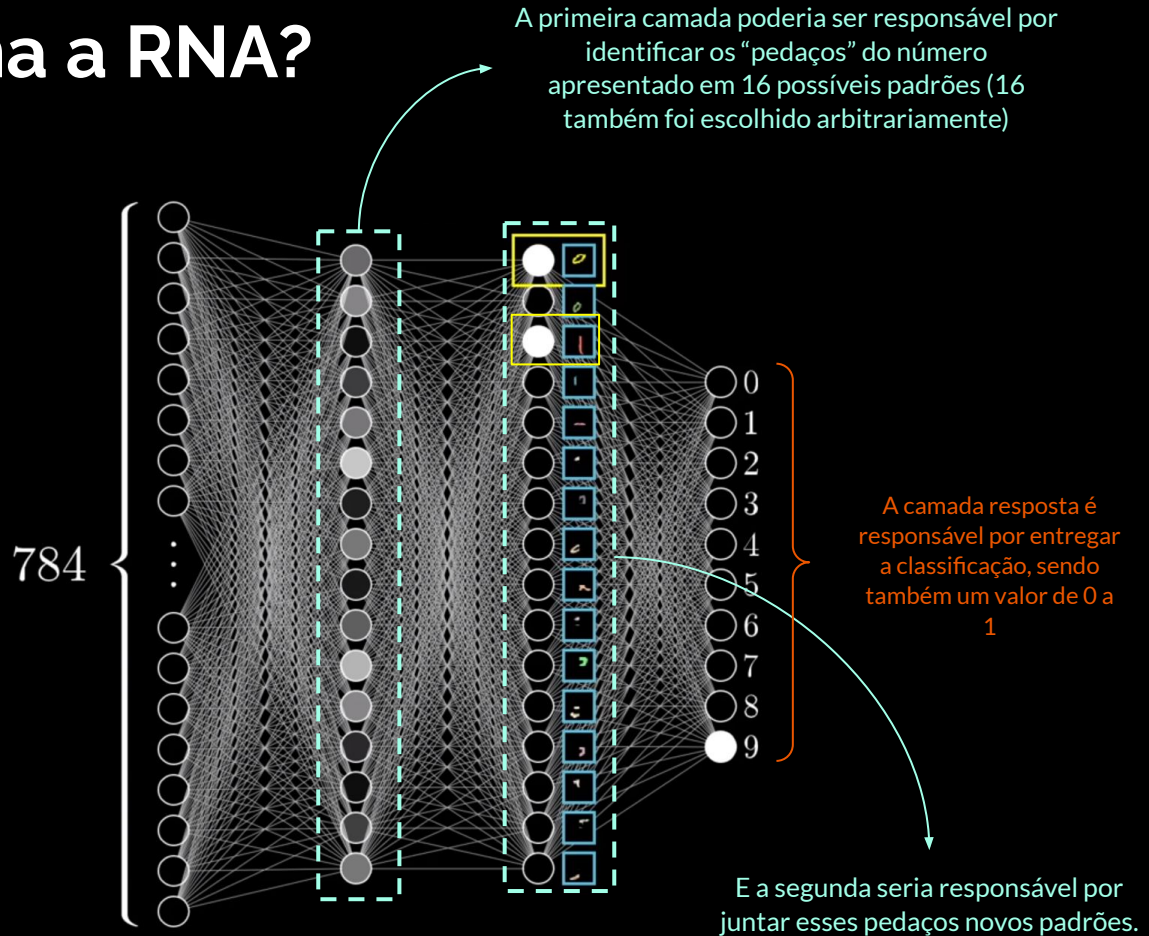
## 2. Como funciona a RNA?

### Camadas ocultas




Eu tenho 784 neurônios que formam um 9, e agora?

Para critério de exemplificação, foram escolhidas arbitrariamente, 2 camadas ocultas, então podemos decompor a formação do número em 2 etapas:




## 2. Como funciona a RNA?

### Ligações entre camadas




Se fizermos algo próximo a essa configuração para os valores de  $W$ , conseguiríamos provavelmente aproximar o padrão desejado, ao buscar pelo máximo da soma.


Vamos pensar, na identificação do seguinte padrão:



Para que o neurônio possa identificar esse padrão vamos atribuir pesos ( $w$ ) a cada uma das ligações com a camada de entrada ( $a$ ). E somar esses valores.



Qual o problema? Essa soma pode ser qualquer valor real, e queremos que seja um valor entre 0 e 1.





## 2. Como funciona a RNA?

### Função de ligação e viés

A função para isso?

Trata-se da função sigmóide




## 2. Como funciona a RNA?

### Resumo final

Para este exemplo, temos 13.002 parâmetros! Sendo  $(16 + 16 + 10)$  parâmetros de viés e  $(784 \times 16 + 16 \times 16 + 16 \times 10)$  parâmetros de pesos.

O aprendizado nesse caso se dá exatamente em encontrar os valores ideais desses parâmetros.



$$a_0^{(1)} = \sigma \left( w_{0,0} a_0^{(0)} + w_{0,1} a_1^{(0)} + \cdots + w_{0,n} a_n^{(0)} + b_0 \right)$$

$$\sigma \left( \begin{bmatrix} w_{0,0} & w_{0,1} & \cdots & w_{0,n} \\ w_{1,0} & w_{1,1} & \cdots & w_{1,n} \\ \vdots & \vdots & \ddots & \vdots \\ w_{k,0} & w_{k,1} & \cdots & w_{k,n} \end{bmatrix} \begin{bmatrix} a_0^{(0)} \\ a_1^{(0)} \\ \vdots \\ a_n^{(0)} \end{bmatrix} + \begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_n \end{bmatrix} \right)$$

$$\sigma(\mathbf{W}\mathbf{a}^{(0)} + \mathbf{b})$$

$$f(a_0, \dots, a_{783}) = \begin{bmatrix} y_0 \\ \vdots \\ y_9 \end{bmatrix}$$




## 3.a. Apresentação dos Dados


O conjunto de dados utilizado na aplicação, apesar de possuir a mesma variável (quantidade de passageiros de linhas aéreas) o **período dos dados presentes no R é diferente**.

O gráfico sugere uma série com uma **tendência positiva** e uma **sazonalidade**. Serão utilizados 132 dados para o conjunto de treinamento, deixando o ano de 1960 como conjunto de teste (12 observações).


O box plot mostra um período de **pico anual principal durante os meses de junho, julho e agosto** (período de férias de verão), assim como mostra um período de **redução** no número de passageiros **no inverno** (dezembro foge um pouco da regra devido ao natal).



Dados do artigo



Dados da prática realizada



## 3.b. Metodologia

Para a determinação da **Camada de Entrada da Rede**, procurou-se modelar a entrada da rede de maneira a captar as componentes da série temporal. Desta forma as unidades foram divididas em três grupos.

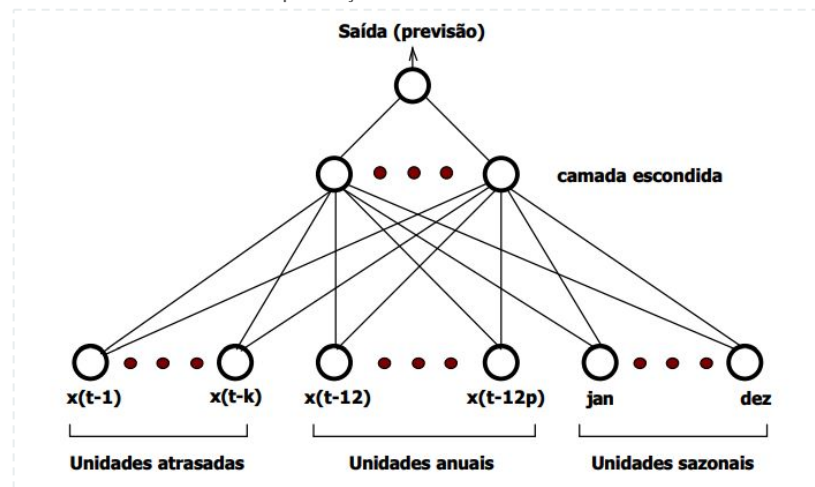
**Notação:** Neural Network Auto-Regressive = **NNAR(p,P,k)[m]**

- $k$  é a quantidade de neurônios na camada oculta;
- $p$  é a quantidade de observações defasadas;
- $P$  é o número de defasagens sazonais;
- $m$  é o número de observações por ano.

A função **nnetar()** do pacote *forecast* ajusta um modelo nesse formato.

Para uma série não-sazonal, o valor padrão de  $p$  é definido pelo número ótimo de uma  $AR(p)$ ; para uma série sazonal, o valor padrão de  $P$  é 1, e  $p$  é escolhido a partir do modelo linear ótimo ajustado aos dados sazonais. E o valor  $k=(p+P+1)/2$ .

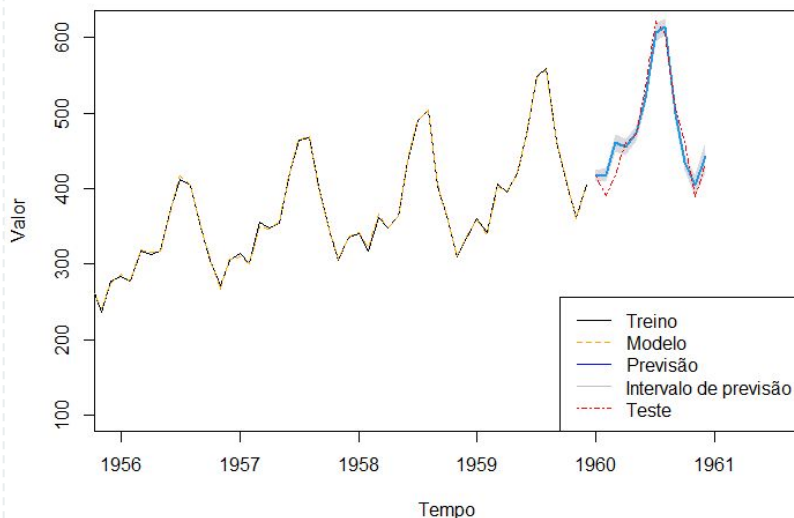
Exemplificação da camada de entrada



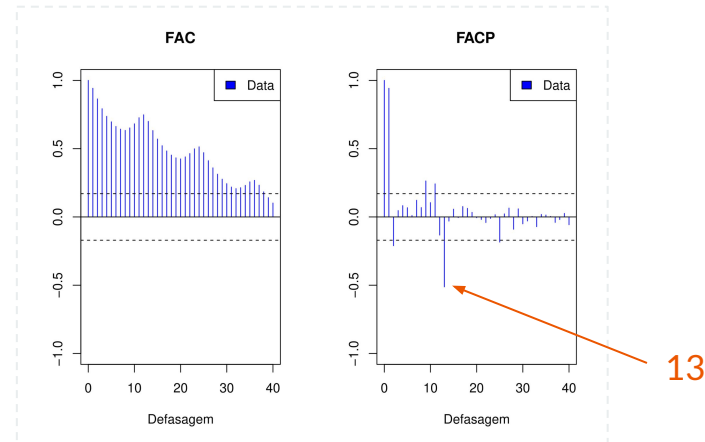
## 3.c. Resultados

No nosso caso mantemos o valor de  $P = 1$  e  $m = 12$ , já que temos uma série com clara sazonalidade. Escolhemos  $p = 13$  devido a FACP que apresenta um pico nessa defasagem. Para o valor de  $k$ , temos:  $k = (13 + 1 + 1) / 2 = 7.5 \approx 7$ .

Previsões para NNAR(13,1,7)[12]



Exemplificação da camada de entrada



O código utilizado foi:

```
mld_ajust <- nnetar(treino, p = 13, P = 1, size = 7,  
repeats = 30)
```

```
prev_ajust <- forecast::forecast(mld_ajust, npaths = 1000, h  
= 12, PI = T, level = c(95))
```

Apesar de não acompanhar tão bem o primeiro salto dos dados, podemos ver que as previsões acompanham muito bem o pico de vendas anual (férias de verão). Além disso, com o **MAPE = 3.24** concluímos que a metodologia adotada possui um bom poder preditivo.

## 4. Conclusão



Em face dos resultados apresentados, pode-se dizer que as **RNAs são uma ferramenta poderosa para a realização de previsão de séries temporais**, capazes de realizar previsões com certo nível de precisão.

A **principal dificuldade** na utilização de redes neurais artificiais na previsão de séries temporais, ainda é a **determinação da arquitetura ótima da rede neural**. A metodologia proposta por este trabalho tem êxito na determinação da camada de entrada da rede, mas apresenta como seu fator limitante a determinação do número de neurônios da camada oculta.