

Backcasting em Séries Temporais

Letícia Emile Rodrigues da Silva

08 de dezembro de 2023

Resumo

Este relatório aborda abrangentemente o conceito e aplicação do backcasting em séries temporais, uma metodologia que permite analisar retrospectivamente e prever eventos passados. Explorando diversos métodos, desde modelos estatísticos tradicionais até abordagens inovadoras como métodos bayesianos e híbridos, o relatório oferece uma visão das ferramentas disponíveis para análises retrospectivas. Apresenta exemplos de estudos de caso em setores como finanças, economia, saúde e meio ambiente, destacando a versatilidade do backcasting. Além disso, a análise de vantagens e desvantagens ressalta a validação retroativa, o aprimoramento da modelagem e a gestão eficaz da incerteza como características positivas, enquanto alerta para possíveis vieses, dependência de dados futuros e complexidade computacional. O exemplo prático de aplicação do backcasting em séries temporais, utilizando a linguagem R, proporciona uma compreensão concreta do processo. O estudo de caso específico, que previu a demanda futura de bicicletas elétricas na Holanda, ilustra a aplicação prática do backcasting, evidenciando sua utilidade para previsões significativas. As conclusões reforçam a importância da implementação cuidadosa do backcasting, considerando o contexto e os desafios específicos.

1 Introdução

As séries temporais desempenham um papel vital em diversos domínios, abrangendo desde previsões meteorológicas até análises financeiras e de saúde pública. Elas proporcionam informações valiosas sobre tendências e padrões ao longo do tempo, permitindo uma compreensão mais profunda de fenômenos complexos. No entanto, a capacidade de modelar e prever séries temporais frequentemente enfrenta desafios quando se lida com aquelas de origem desconhecida ou mal compreendida.

Backcasting é um método usado na análise de séries temporais para gerar uma sequência hipotética de eventos ou valores que resultariam em um determinado resultado final ou ponto final. Envolve trabalhar de trás para frente a partir do resultado final conhecido para identificar as etapas ou fatores que precisariam ser implementados para alcançar esse resultado.

Um uso comum do backcasting é na previsão de tendências ou eventos futuros. Por exemplo, se uma empresa pretende atingir um determinado nível de receitas em cinco anos, pode utilizar o backcasting para identificar os principais impulsionadores ou fatores que teriam de estar em vigor para atingir esse nível de receitas. Isso pode incluir fatores como crescimento do mercado, desenvolvimento de produtos e estratégias de vendas. Ao identificar esses fatores-chave, a empresa pode então desenvolver um plano para alcançar o resultado desejado.

Outro uso do backcasting é na análise de eventos ou tendências passadas. Por exemplo, se uma empresa quiser compreender porque é que as suas vendas diminuíram durante um determinado período, pode utilizar o backcasting para identificar os principais impulsionadores ou fatores que podem ter contribuído para o declínio. Isto pode incluir fatores como mudanças no comportamento do consumidor, concorrência

no mercado ou mudanças nas estratégias de negócios da própria empresa. Ao identificar estes fatores, a empresa pode então tomar medidas para abordar as causas subjacentes do declínio e evitar quedas semelhantes no futuro.

O backcasting também pode ser usado para avaliar a viabilidade de um plano ou estratégia proposta. Por exemplo, se uma empresa quiser lançar um novo produto, ela pode usar o backcasting para identificar os principais impulsionadores ou fatores que precisariam estar em vigor para tornar o produto um sucesso. Isto pode incluir fatores como a procura do mercado, a capacidade de produção e os recursos financeiros. Ao identificar estes fatores-chave, a empresa pode então determinar se o plano proposto é realista e exequível.

No geral, o backcasting é uma ferramenta útil para identificar os principais impulsionadores e fatores que influenciam um determinado resultado ou tendência, e para desenvolver planos e estratégias para alcançar os resultados desejados. Permite que as empresas e organizações compreendam melhor as forças que atuam nos seus mercados e indústrias e tomem decisões mais informadas sobre o futuro.

Em síntese, este relatório está estruturado de maneira a abranger distintos aspectos do backcasting em séries temporais. Após a presente Introdução, a **Seção 2** explora a metodologia adotada, discutindo métodos relevantes e incluindo subseções que proporcionam uma visão detalhada. A **Seção 3** se dedica a uma análise breve, mas crucial, de exemplos onde se aplica o contexto do estudo, citando vantagens e desvantagens. Adiante, a **Seção 4** aborda uma comparação entre backcasting e forecasting, com o intuito de introduzir melhor a **Seção 5**, que aborda as ferramentas e pacotes de software utilizados durante o processo de backcasting. Na **Seção 6**, apresenta-se um estudo de caso específico de backcasting. Por fim, na **Seção 7**, encontram-se as conclusões e considerações finais, onde são destacados insights cruciais e conclusões derivadas do estudo, seguido das Referências utilizadas.

2 Metodologia

O desenvolvimento de métodos de backcasting em séries temporais tem sido um campo de pesquisa ativo, visando aprimorar a precisão das previsões retrospectivas. Diferentes abordagens e técnicas têm sido propostas para enfrentar os desafios únicos associados a esse método. A seguir, serão discutidos alguns métodos notáveis.

2.1 Modelos Estatísticos Tradicionais

Os modelos estatísticos tradicionais, como ARIMA (AutoRegressive Integrated Moving Average) e SARIMA (Seasonal ARIMA), são amplamente reconhecidos e utilizados na análise de séries temporais. O ARIMA incorpora componentes autoregressivos, de médias móveis e de diferenciação para capturar padrões temporais em dados. Quando há sazonalidade nos dados, o SARIMA estende o ARIMA incluindo componentes sazonais. Esses modelos baseiam-se em métodos estatísticos clássicos, proporcionando uma estrutura sólida para a modelagem de séries temporais [1].

2.2 Métodos Bayesianos

Os métodos Bayesianos têm emergido como uma abordagem poderosa no contexto de backcasting em séries temporais. A principal característica é a incorporação explícita da incerteza, oferecendo uma perspectiva mais completa sobre as previsões. A aplicação de métodos Bayesianos permite a modelagem

de distribuições de probabilidade para os parâmetros do modelo, resultando em intervalos de confiança robustos. Gelman et al. (2014) [2] fornecem uma referência abrangente sobre análise bayesiana de dados, enquanto outros trabalhos, como Chatfield (2004) [3], exploram a aplicação específica desses métodos em séries temporais.

2.3 Métodos Híbridos

Os métodos híbridos representam uma abordagem inovadora que combina elementos de diferentes técnicas para melhorar a eficácia da previsão. A fusão de modelos estatísticos tradicionais, como ARIMA, com técnicas de machine learning, como redes neurais, proporciona um equilíbrio entre interpretabilidade e capacidade preditiva. Esta abordagem é particularmente valiosa em cenários complexos [4].

2.4 Métodos de Amostragem Sequencial

Os métodos de amostragem sequencial, exemplificados pelo filtro de Kalman, desempenham um papel crucial no aprimoramento das análises de backcasting em séries temporais. Em ambientes nos quais dados futuros são incorporados incrementalmente, essas abordagens permitem ajustes contínuos nos modelos, utilizando observações futuras para retroceder previsões no tempo. No caso específico do filtro de Kalman, sua aplicação no backcasting visa melhorar retrospectivamente as previsões, especialmente em cenários dinâmicos com disponibilidade dinâmica de dados e revisões nos registros históricos. A adaptação contínua do modelo com base em novas observações contribui para uma compreensão mais refinada das tendências passadas, promovendo, assim, maior precisão e robustez nas análises de backcasting em séries temporais [5].

Considerações

Os métodos de backcasting em séries temporais representam uma área dinâmica de pesquisa, e a escolha do método adequado depende do contexto específico da aplicação e das características dos dados. A combinação de abordagens estatísticas clássicas, técnicas de machine learning e métodos bayesianos oferece uma gama de opções para enfrentar os desafios inerentes ao backcasting.

3 Aplicações de backcasting, vantagens e desvantagens

O backcasting em séries temporais é uma técnica versátil com ampla aplicabilidade em diversas áreas, como finanças, economia, ciência ambiental, entre outras. A seguir, apresentam-se exemplos concretos de sua aplicação.

- **Previsão de Demanda:** Empresas podem utilizar o backcasting para antecipar a demanda futura de produtos ou serviços com base em dados históricos, possibilitando um planejamento eficiente de produção e estoque [6].
- **Análise de Tendências:** A análise retrospectiva de tendências históricas por meio do backcasting é útil para prever a continuidade dessas tendências no futuro, oferecendo insights valiosos para

antecipar mudanças no mercado ou no ambiente de negócios [4].

- **Modelagem Ambiental:** O backcasting é aplicado na modelagem do impacto de mudanças ambientais passadas, sendo instrumental para prever como essas mudanças podem afetar o meio ambiente no futuro, especialmente em relação a questões climáticas e ambientais.
- **Previsão de Preços:** Empresas que precisam planejar estratégias de precificação podem recorrer ao backcasting para prever os preços futuros com base em dados históricos, contribuindo para decisões informadas [3].
- **Análise de Risco:** O backcasting é empregado na análise de risco histórico em séries temporais, fornecendo previsões sobre como esse risco pode evoluir no futuro. Isso é particularmente útil para prever riscos financeiros e outros tipos de riscos.

O backcasting em séries temporais destaca-se em várias áreas, ampliando seu impacto para além de aplicações específicas. Na Área Financeira, é uma ferramenta frequente na avaliação retrospectiva de investimentos, identificação de padrões de mercado e compreensão do impacto de eventos históricos nas tendências financeiras.

Já na Economia, por exemplo, a análise retrospectiva de indicadores econômicos proporciona uma compreensão mais profunda das dinâmicas do mercado, auxiliando na formulação de políticas e estratégias diante de desafios econômicos. Na Área da Saúde, o backcasting é aplicado para a análise retrospectiva de dados epidemiológicos, permitindo identificar padrões em surtos de doenças e avaliar a eficácia de intervenções passadas.

Esses exemplos destacam a versatilidade do backcasting em séries temporais, evidenciando sua aplicação em contextos diversos. A análise retrospectiva dessas séries fornece uma base sólida para a tomada de decisões informadas e a formulação de estratégias eficazes.

Vantagens e desvantagens

O backcasting apresenta diversas vantagens significativas. Uma delas é a validação retroativa, que permite avaliar a eficácia do modelo ao utilizar dados futuros para prever eventos passados [1]. Além disso, essa técnica contribui para o aprimoramento da modelagem, aumentando a robustez dos modelos e capacitando-os a capturar tendências complexas e padrões nos dados históricos de forma mais precisa. Outro benefício notável é a gestão eficaz da incerteza nas previsões, uma vez que o backcasting oferece a oportunidade de analisar e lidar com a incerteza associada, incorporando intervalos de confiança robustos às projeções [2]. Essas características tornam o backcasting uma abordagem valiosa na análise de séries temporais.

Apesar das vantagens, o backcasting também apresenta desvantagens significativas. Uma delas é o risco de introdução de viés nas previsões, especialmente quando a informação futura não é representativa da situação passada, podendo comprometer a precisão do modelo. Além disso, a eficácia do backcasting está intrinsecamente ligada à disponibilidade de dados futuros; em situações em que esses dados não estão acessíveis ou são incertos, a aplicação do backcasting pode ser limitada. Outro ponto a considerar é a complexidade computacional, principalmente em modelos avançados que incorporam técnicas de machine learning, podendo exigir recursos computacionais substanciais e introduzir complexidade na

implementação [7]. Essas desvantagens destacam a importância de considerar cuidadosamente o contexto e as limitações antes de optar pelo uso do backcasting em séries temporais.

Considerações Adicionais

A eficácia do backcasting é contextual e pode variar conforme a aplicação. Em setores como finanças e epidemiologia, onde a disponibilidade de dados futuros é mais consistente, o backcasting pode ser mais aplicável [4]. Para assegurar a confiabilidade das previsões, é crucial fornecer transparência sobre a origem e a natureza dos dados futuros utilizados. Além disso, uma comunicação efetiva dos resultados é essencial [1].

Em conclusão, embora o backcasting ofereça vantagens como validação retroativa e potencial aprimoramento da modelagem, sua implementação deve ser cuidadosa, considerando o contexto específico e os desafios associados à dependência de dados futuros.

4 Comparação entre Backcasting e Forecasting

Forecasting e backcasting são duas abordagens distintas na análise temporal, cada uma com sua própria perspectiva e aplicação. O forecasting é uma técnica orientada para o futuro, usando dados históricos para prever eventos ou tendências que ocorrerão posteriormente. Por outro lado, o backcasting tem uma orientação retrospectiva, analisando eventos passados a partir de um resultado conhecido.

No forecasting, a ênfase está na extrapolação de dados históricos para fazer previsões sobre o que pode acontecer no futuro. Essa abordagem é comumente aplicada em previsões de demanda, vendas, tendências de mercado e eventos futuros. É uma ferramenta valiosa para orientar a tomada de decisões estratégicas, proporcionando insights para a formulação de planos e estratégias futuras.

O backcasting, por outro lado, trabalha de trás para frente. Ele começa com um resultado final conhecido e busca identificar as causas ou eventos que levaram a esse resultado. É frequentemente usado para análise de eventos passados, compreensão de quedas de desempenho e avaliação retrospectiva. O backcasting pode contribuir para ajustes estratégicos ao aprender com eventos passados, melhorando a tomada de decisões presentes e futuras.

Ambas as abordagens lidam com a incerteza, mas de maneiras diferentes. O forecasting lida com a incerteza inerente ao futuro, buscando reduzi-la por meio de modelagem e análise estatística. Por outro lado, o backcasting oferece a oportunidade de analisar e lidar com a incerteza associada a eventos passados, contribuindo para uma compreensão mais refinada das tendências passadas.

Em resumo, enquanto o forecasting orienta a preparação para o futuro, o backcasting examina o passado para entender causas e efeitos, visando melhorar decisões presentes e futuras. Ambas as abordagens têm suas aplicações específicas e podem ser utilizadas de forma complementar para análises temporais abrangentes. A compreensão dessas abordagens é essencial para embasar a discussão subsequente sobre ferramentas específicas de análise temporal.

5 Ferramentas e pacotes de software para backcasting

Ao explorar a aplicação do backcasting em séries temporais, é essencial considerar as ferramentas e pacotes de software disponíveis que facilitam a implementação dessa técnica. Diversas opções oferecem suporte aos praticantes e pesquisadores que buscam realizar análises retrospectivas e previsões em séries temporais. Entre as ferramentas mais amplamente utilizadas, destacam-se R e Python, ambas reconhecidas por suas robustas bibliotecas estatísticas e de machine learning.

No ambiente R, pacotes como `forecast`, `TSA` e `fable` são exemplos notáveis, proporcionando funcionalidades específicas para análise temporal e previsão. Em Python, bibliotecas como `Statsmodels`, `Prophet` e `Scikit-learn` oferecem recursos poderosos para modelagem de séries temporais e técnicas avançadas de machine learning.

Além dessas opções, ferramentas dedicadas, como o IBM SPSS Statistics e o MATLAB, oferecem ambientes de desenvolvimento integrados para análises estatísticas e modelagem temporal. O uso de ferramentas específicas pode depender das necessidades do usuário e da familiaridade com determinada linguagem de programação.

Essas são apenas algumas das ferramentas e pacotes de software disponíveis para backcasting em séries temporais. A escolha da ferramenta ou pacote depende do conjunto de dados e do objetivo da análise. A seguir, é apresentado um exemplo simples de aplicação do backcasting em séries temporais utilizando a linguagem de programação R. Esse caso ilustrativo destaca o processo básico de implementação da técnica, proporcionando uma visão prática para compreensão dos passos envolvidos.

Exemplo

Suponha que se tem uma série temporal **x** e deseja-se fazer previsões para o passado. Primeiro, precisa-se inverter a ordem dos dados da série temporal usando a função **rev()**. Em seguida, você pode usar a função **forecast()** do pacote **forecast** para fazer previsões para o futuro. Finalmente, você pode inverter a ordem dos dados da previsão novamente usando a função **rev()**. Na **Figura 1**, encontra-se um exemplo do código que realiza essa tarefa.

```

library(forecast)

# Crie uma série temporal
x <- ts(c(1:24), start = c(2008, 1), frequency = 12)

# Inverta a ordem dos dados da série temporal
rev_x <- rev(x)

# Faça previsões para o futuro
fc <- forecast(rev_x, h = 12)

# Inverta a ordem dos dados da previsão novamente
fc_rev <- rev(fc$mean)

# Plote os resultados
plot(x)
lines(fc_rev, col = "red")

```

Figura 1. Exemplo de código R para Aplicação de Backcasting em Série Temporal.

Este código cria uma série temporal **x** com 24 observações mensais a partir de janeiro de 2008. Em seguida, ele inverte a ordem dos dados da série temporal usando a função **rev()**. Depois, ele usa a função **forecast()** para fazer previsões para os próximos 12 meses. Finalmente, ele inverte a ordem dos dados da previsão novamente usando a função **rev()** e plota os resultados. Um exemplo semelhante pode ser encontrado em [8].

Em alguns casos, é benéfico realizar um "backcast" em uma série temporal, ou seja, fazer previsões no sentido inverso do tempo. Embora não haja funções integradas em R para essa finalidade, é simples de implementar, basta inverter um objeto de série temporal (ts) e um objeto de previsão (forecast).

Dessa forma, é possível aplicar essas funções para retroceder qualquer série temporal. Um exemplo prático [8] é ilustrado usando dados de comércio varejista trimestral na área do euro, abrangendo o período de 1996 a 2011. O objetivo é realizar um backcast para prever os anos 1994-1995. Assim, temos o gráfico da série, conforme **Figura 2**.

Backcasts from ARIMA(0,1,3)(0,1,1)[4]




Figura 2. Retrospectivas para o comércio retalhista trimestral na área do euro utilizando um modelo ARIMA.

6 Exemplo estudo de caso de backcasting

O estudo de caso, destacado na publicação do *Journal of Business Research*, empregou a técnica de backcasting para antecipar a demanda futura de bicicletas elétricas na Holanda. A proposta da pesquisa consistiu em projetar a procura por bicicletas elétricas nos anos subsequentes, utilizando como base os dados históricos das vendas desses veículos no país, abrangendo o período de 2008 a 2015. O objetivo principal foi estender essa previsão para além desse intervalo temporal, visando compreender a demanda projetada até o ano de 2025.

Os pesquisadores usaram um modelo de backcasting baseado em uma abordagem de regressão linear múltipla para prever a demanda futura de bicicletas elétricas. O modelo incluiu variáveis como o preço das bicicletas elétricas, a renda média dos consumidores e a disponibilidade de infraestrutura de ciclismo.

Os resultados do estudo mostraram que a demanda futura de bicicletas elétricas na Holanda provavelmente aumentaria nos próximos anos, impulsionada por fatores como a conscientização ambiental e a melhoria da infraestrutura de ciclismo. Os pesquisadores também identificaram oportunidades para as empresas de bicicletas elétricas se concentrarem em segmentos específicos do mercado, como jovens adultos e idosos.

O estudo é importante porque fornece informações valiosas para as empresas de bicicletas elétricas que desejam expandir seus negócios na Holanda. Ele também destaca a importância do backcasting em séries temporais como uma ferramenta para prever a demanda futura de produtos e serviços.

Em resumo, o estudo de caso publicado na revista *Journal of Business Research* usou backcasting para prever a demanda futura de bicicletas elétricas na Holanda com base em dados históricos de vendas de bicicletas elétricas. O estudo mostrou que a demanda futura de bicicletas elétricas na Holanda provavelmente aumentaria nos próximos anos, impulsionada por fatores como a conscientização ambiental e a melhoria da infraestrutura de ciclismo.

7 Conclusões e Considerações Finais

Em conclusão, este relatório proporcionou uma exploração abrangente do backcasting em séries temporais, destacando sua aplicação em diversas áreas e fornecendo insights valiosos para aqueles envolvidos em análises retrospectivas e previsões. A metodologia detalhada abordou métodos tradicionais, bayesianos, híbridos e de amostragem sequencial, ressaltando a diversidade de abordagens disponíveis.

A análise de vantagens, desvantagens e considerações adicionais ofereceu uma visão equilibrada do backcasting, destacando seu potencial aprimoramento da modelagem, validação retroativa e gestão eficaz da incerteza. No entanto, alertou para desafios como viés, dependência de dados futuros e complexidade computacional, enfatizando a necessidade de uma implementação cuidadosa.

O estudo de caso exemplar, prevendo a demanda futura de bicicletas elétricas na Holanda, trouxe uma perspectiva prática, demonstrando a aplicação efetiva do backcasting em cenários do mundo real. Essa análise reforçou não apenas a utilidade da técnica para previsões significativas, mas também sua relevância em setores diversos.

Em última análise, este relatório visa enriquecer a compreensão do backcasting em séries temporais. Conclui-se que, embora o backcasting ofereça vantagens distintas, sua aplicação demanda uma consideração cuidadosa do contexto específico e uma compreensão profunda dos desafios associados à dependência de dados futuros.

Estas conclusões não apenas sintetizam as principais descobertas deste relatório, mas também destacam a importância contínua do backcasting como uma ferramenta valiosa para análises retrospectivas e previsões em séries temporais.

Referências

- [1] Box, G.E., Jenkins, G.M., & Reinsel, G.C. (1994). Time Series Analysis: Forecasting and Control.
- [2] Gelman, A., Carlin, J.B., Stern, H.S., Dunson, D.B., Vehtari, A., & Rubin, D.B. (2014). Bayesian Data Analysis.
- [3] Chatfield, C. (2004). The Analysis of Time Series: An Introduction.
- [4] Hyndman, R.J., & Athanasopoulos, G. (2018). Forecasting: Principles and Practice.
- [5] Durbin, J., & Koopman, S.J. (2012). Time Series Analysis by State Space Methods.
- [6] Balakrishnan, N., Castillo, E., & Sarabia, J. M. (2013). Backcasting in Time Series Analysis. Springer Science & Business Media.
- [7] López de Prado, M. (2018). Advances in Financial Machine Learning.
- [8] Fonte: <https://otexts.com/fpp2/backcasting.html>