

Séries Temporais

Trabalho III

Mário Prado Celestino Júnior

Dezembro 2023

1 Resumo

Este trabalho acadêmico apresenta uma análise aprofundada do Prophet, uma ferramenta de previsão de séries temporais desenvolvida pelo Facebook. O Prophet é uma abordagem flexível e poderosa projetada para lidar com as complexidades das séries temporais, sendo amplamente utilizado em diversas áreas, como finanças, meteorologia e análise de negócios. Neste documento, exploramos os fundamentos teóricos por trás do Prophet, destacando suas características distintivas, algoritmos subjacentes e casos de uso comuns. Além disso, examinamos a implementação prática do Prophet em estudos de caso específicos e avaliamos seu desempenho em comparação com outras abordagens de previsão de séries temporais.

2 Introdução

As séries temporais representam uma forma dinâmica de dados, onde as observações são coletadas sequencialmente ao longo do tempo. Essas séries oferecem uma janela única para compreender a evolução de fenômenos, identificando padrões sazonais, tendências e comportamentos cíclicos que podem ser cruciais para a tomada de decisões informadas. No entanto, a análise de séries temporais não está isenta de desafios, uma vez que a natureza temporal dos dados pode introduzir complexidades como sazonalidade irregular, efeitos de feriados e flutuações imprevisíveis.

A necessidade premente de prever valores futuros nessas séries motivou o desenvolvimento de uma variedade de técnicas e ferramentas, cada uma enfrentando desafios específicos. Nesse contexto, o Prophet, uma inovação desenvolvida pelo Facebook, se destaca como uma solução abrangente e eficiente. Este modelo foi projetado para enfrentar os desafios intrínsecos das séries temporais, oferecendo

uma abordagem automática que simplifica significativamente o processo de previsão.

Uma das principais vantagens do Prophet é a sua rapidez e versatilidade. Ao ser um modelo automático, ele reduz a carga de trabalho manual associada à seleção de parâmetros e à configuração complexa, permitindo uma implementação eficiente mesmo por usuários sem expertise avançada em séries temporais. Essa característica é particularmente valiosa em ambientes onde a agilidade na resposta a mudanças nos dados é essencial.

O objetivo deste trabalho é explorar, testar e comparar o Prophet com outras técnicas de previsão. Iremos investigar a eficácia do Prophet em capturar a complexidade das séries temporais, avaliar sua precisão nas previsões e comparar seus resultados com outras abordagens tradicionais de previsão.

3 Metodologia

Para efetuar a comparação entre o Prophet, os modelos ARIMA e NNETAR, utilizamos dados do índice Ibovespa no período compreendido entre o ano de 2018 e a data atual. Esse intervalo foi escolhido com o propósito de analisar três diferentes horizontes temporais: 1 ano, 2 anos e 5 anos. Essa abordagem visa compreender como diferentes períodos influenciam o desempenho de cada modelo.

Destaca-se que o ano de 2023 será separado especificamente para a comparação das previsões. A escolha do Ibovespa como conjunto de dados foi motivada por sua relevância como indicador do desempenho do mercado de ações brasileiro. É importante notar que a seleção desse conjunto específico foi orientada pela presença de lacunas em dias não úteis, proporcionando um ambiente desafiador para os modelos de previsão lidarem com a volatilidade inerente aos mercados financeiros.

3.1 Implementação do Prophet

Utilizamos a implementação do Prophet disponível na biblioteca do Facebook para R. Configuramos o modelo considerando os parâmetros padrão, ajustando-os conforme necessário durante o processo de validação.

3.2 Implementação dos Modelos ARIMA e NNETAR

Para os modelos ARIMA e NNETAR, recorreremos à biblioteca estatística e econométrica Forecast disponível em linguagem R. Configuramos os parâmetros dos modelos ARIMA utilizando a função `auto.arima`, enquanto para o modelo NNETAR, utilizamos a função `nnetar`,

3.3 Treinamento e Validação

Dividimos o conjunto de dados em conjuntos de treinamento e validação, utilizando os dados de 2023 para avaliar a capacidade preditiva dos modelos. As previsões foram geradas para um horizonte de 20 dias úteis, equivalente a um mês corrido. O processo de previsão iniciou-se em 01/01/2023, e após cada previsão, as métricas de erro foram registradas.

A metodologia adotada envolve adicionar o primeiro dia dos dados de teste ao conjunto de treinamento após cada previsão. Em seguida, uma nova previsão é realizada para os próximos 20 dias úteis, e assim por diante. Esse procedimento foi repetido para cada horizonte temporal (1 ano, 2 anos e 5 anos), tratando-os independentemente.

Após a coleta de todas as métricas de erro para cada modelo e horizonte temporal, calculamos a média do módulo de cada medida de erro, assim como o desvio padrão. Esses valores agregados foram armazenados para análises futuras, proporcionando uma visão consolidada do desempenho preditivo dos modelos em diferentes cenários temporais.

3.4 Considerações Finais

A metodologia adotada busca garantir uma comparação robusta entre o Prophet, ARIMA e NNETAR, considerando as características específicas do conjunto de dados do Ibovespa e a complexidade associada aos mercados financeiros. As análises resultantes proporcionarão considerações valiosas sobre a eficácia de cada modelo na previsão de séries temporais financeiras, destacando suas vantagens e limitações em um contexto prático e desafiador.

4 Dados do IBOVESPA

Conforme mencionado anteriormente, empregaremos os dados do Ibovespa para as análises, especificamente concentrando-nos nos valores de fechamento.

Figura 1: Série do IBOVESPA com início em 2015.



Para todos os modelos, optamos por manter os dados sem qualquer tratamento adicional, preservando unicamente as datas e valores correspondentes. Essa abordagem foi adotada com o intuito de desafiar os métodos automáticos inerentes a cada processo, expondo-os a situações mais próximas da realidade. Nesse contexto, a decisão de não realizar pré-processamento ou suavização tem o propósito de confrontar os modelos com a volatilidade, sazonalidades e outros padrões complexos inerentes aos dados não tratados.

Essa escolha não apenas representa um desafio mais rigoroso para os métodos automáticos, mas também contribui para ampliar a robustez da avaliação do desempenho dos modelos. Ao se abster de manipulações adicionais nos dados, como

suavizações excessivas ou ajustes manuais de outliers, a avaliação torna-se mais fiel às condições enfrentadas pelos modelos na prática.

5 Modelos

A seguir, apresentamos tabelas contendo os resultados das medidas de erro para cada interação entre modelos e horizontes da série temporal, assim com a tabela dos desvios padrões.

Modelo	Horizonte	Medidas de Erro				
		ME	RMSE	MAE	MPE	MAPE
ARIMA	1 ano	2802.75	3682.68	3214.23	2.53	2.90
ARIMA	2 anos	2700.07	3594.97	3124.16	2.44	2.82
ARIMA	5 anos	3439.69	4619.08	4018.28	3.16	3.69
PROPHET	1 ano	5296.92	6028.30	5591.12	4.78	5.05
PROPHET	2 anos	4852.75	5911.22	5282.18	4.42	4.80
PROPHET	5 anos	7758.64	8712.74	8143.10	7.60	7.97
NNETAR	1 ano	2993.28	3872.51	3364.45	2.69	3.02
NNETAR	2 anos	2622.51	3523.59	3057.27	2.36	2.75
NNETAR	5 anos	3299.42	4465.19	3883.00	3.00	3.53

Modelo	Horizonte	Desvio Padrão das Medidas de Erro				
		ME	RMSE	MAE	MPE	MAPE
ARIMA	1 ano	3264.77	1855.19	1717.25	2.95	1.57
ARIMA	2 anos	3262.69	1880.92	1753.17	2.95	1.61
ARIMA	5 anos	4355.38	2457.48	2248.79	4.03	2.13
PROPHET	1 ano	6100.70	2827.57	2871.41	5.52	2.71
PROPHET	2 anos	5830.13	3111.64	3043.63	5.33	2.87
PROPHET	5 anos	7637.01	4657.81	4707.02	7.59	4.96
NNETAR	1 ano	3739.80	2203.52	2055.49	3.36	1.85
NNETAR	2 anos	3223.64	1946.87	1796.75	2.90	1.62
NNETAR	5 anos	4200.05	2389.22	2186.63	3.83	1.99

Ao examinar as tabelas acima, observamos fenômenos interessantes. Conforme o horizonte de previsão se estende para 5 anos, todas as medidas de erro experimentam um aumento significativo. Essa tendência sugere que a série temporal pode estar sendo impactada por valores antigos. Em outras palavras, a partir de um determinado ponto entre 2 e 5 anos, os valores mais antigos perdem significância para a predição de valores futuros, criando uma influência prejudicial nos modelos.

Além disso, notamos que o Prophet apresenta os maiores valores de erro e desvio padrão em comparação com os outros dois modelos em todos os horizontes testados. Isso sugere que, nos cenários específicos avaliados, o Prophet pode não ter desempenhado tão bem quanto o ARIMA e o NNETAR.

Resultado da Regressão Linear Múltipla para o MAPE

Coeficientes	Estimativa
Intercepto	2.90
Modelo NNETAR	0.12
Modelo PROPHET	2.15
Horizonte 2 anos	-0.08
Horizonte 5 anos	0.79
Modelo NNETAR:Horizonte 2 anos	-0.19
Modelo PROPHET:Horizonte 2 anos	-0.16
Modelo NNETAR:Horizonte 5 anos	-0.27
Modelo PROPHET:Horizonte 5 anos	2.13

Ao analisar a Regressão Linear Múltipla para o MAPE, é notável que o modelo Prophet exibe uma influência negativa significativa. Esta tendência é mais pronunciada no horizonte de 5 anos. Em contraste, as demais observações não apresentam diferenças estatisticamente significantes.

6 Conclusões

Este trabalho proporcionou uma análise aprofundada do Prophet, uma ferramenta de previsão de séries temporais desenvolvida pelo Facebook. Ao explorar seus fundamentos teóricos, características distintivas e algoritmos subjacentes, buscamos compreender seu desempenho em comparação com abordagens tradicionais, como ARIMA e NNETAR.

O Prophet destaca-se pela sua rapidez, versatilidade e abordagem automática, simplificando o processo de previsão. No entanto, ao confrontá-lo com os modelos ARIMA e NNETAR em cenários financeiros desafiadores, observamos tendências interessantes.

A análise dos resultados revelou que, à medida que o horizonte de previsão aumenta para 5 anos, todas as medidas de erro sofrem um aumento significativo. Isso sugere que a série temporal pode ser influenciada por valores mais antigos, impactando a precisão das previsões.

Além disso, o Prophet apresentou os maiores valores de erro e desvio padrão em comparação com os outros modelos testados. Especificamente, a Regressão Linear Múltipla indicou uma influência negativa significativa do Prophet, especialmente no horizonte de 5 anos.

Essas descobertas destacam a importância de considerar o horizonte temporal ao avaliar modelos de previsão de séries temporais. Além disso, apontam para nuances no desempenho do Prophet em cenários específicos, sugerindo a necessidade de ajustes ou combinação com outras abordagens para otimizar resultados.

Além disso, é relevante mencionar que, em nossas análises, o Prophet também se mostrou mais lento em comparação com os modelos ARIMA e NNETAR. Essa característica pode ser relevante, especialmente em contextos nos quais a agilidade na resposta a mudanças nos dados é essencial. A compreensão das limitações e tendências específicas de cada modelo, incluindo fatores como desempenho computacional, é crucial para a seleção informada e bem-sucedida de ferramentas de previsão de séries temporais.